Business Intelligence

Proyecto final · Entrega 1

Diagnóstico, estrategia y diseño

Comercial Andina S.A.S. — Diagnóstico de ventas, rentabilidad y demanda

Integrante	Código
Arturo González	507242006
[Nombre del integrante 2]	[Agregar código]
[Nombre del integrante 3, si aplica]	[Agregar código]

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	23/10/2026
Repositorio	Bi-proyecto-equipo507242006

Resumen de la entrega

Comercial Andina S.A.S. es una cadena ficticia de tiendas de barrio que tiene dificultades para organizar y analizar la información de sus ventas, costos y productos. Por eso, se propone crear una solución de Business Intelligence que permita reunir la información en un solo lugar y entender mejor cómo está funcionando el negocio. La idea es analizar las ventas, los descuentos y las ganancias por fecha, producto, tienda y canal de venta. En esta primera entrega se estudiará la situación actual y se diseñará una propuesta de solución, sin desarrollar todavía el sistema ni los tableros.

1. Caso de negocio

Comercial Andina S.A.S. es una empresa ficticia dedicada a la venta de productos de consumo diario. Para este proyecto, se plantea que la empresa tiene varias tiendas y que necesita mejorar la forma en que organiza la información de sus ventas y productos. El objetivo es proponer una solución que le ayude a conocer mejor sus resultados, identificar qué productos se venden más y tomar decisiones más acertadas sobre las compras y el inventario.

1.1 Organización y contexto

La empresa pertenece al sector del comercio minorista y, para este caso, se supone que cuenta con seis tiendas ubicadas en Bogotá y municipios cercanos. Su principal responsable es el gerente comercial, quien trabaja junto con el área de compras y los encargados de cada tienda.

Actualmente, la empresa tiene dificultades para saber con claridad cuáles son los productos más rentables, qué tiendas venden más y cómo cambian los resultados con el paso del tiempo. También necesita mejorar la planificación del inventario para evitar quedarse sin productos importantes o comprar cantidades que no se necesitan. Por esta razón, se propone organizar la información para que sea más fácil de consultar y utilizar al momento de tomar decisiones.

1.2 Síntomas de arquitectura accidental

Uno de los principales problemas de Comercial Andina S.A.S. es que la información se encuentra separada en diferentes archivos y no todas las áreas la organizan de la misma manera. Esto dificulta comparar los resultados de las tiendas y encontrar información confiable cuando se necesita tomar una decisión.

Por ejemplo, pueden existir diferencias en los nombres de los productos, fechas registradas de distintas formas, datos incompletos o ventas que aparecen repetidas. Estos problemas pueden generar confusiones al calcular los ingresos y las ganancias.

Como la empresa es ficticia, estos ejemplos se plantean como posibles situaciones que se revisarán al preparar los datos del proyecto. La propuesta busca reunir la información, organizarla con criterios comunes y facilitar su consulta. Así, la empresa podrá contar con datos más claros y tomar mejores decisiones sobre sus ventas, compras e inventario.

#	Síntoma	Evidencia en el caso	Capa afectada
S1	Archivos de venta separados por tienda	Cada tienda entrega un archivo independiente; no existe una tabla consolidada de ventas y costos.	Fuentes / Integración
S2	Catálogos inconsistentes	Un mismo producto puede aparecer con SKU, nombre o categoría escritos de forma diferente entre archivos; se propone probar códigos como P-01 y P01.	Integración / Datos
S3	Fechas y valores sin formato común	Se propone una tienda con fechas dd/mm/aaaa y otra con mm-dd-aaaa; costos y precios pueden mezclarse entre pesos y miles de pesos.	Fuentes / Integración / Gobierno

1.3 Preguntas de negocio

#	Pregunta	Tipo (BI, BA o Big Data)	Por qué es de ese tipo
P0	¿Qué productos y tiendas generan mayor y menor utilidad por mes?	BI	Resume resultados históricos estructurados con métricas y dimensiones.
P1	¿Cómo cambian las ventas, descuentos y utilidad por categoría, ciudad y canal?	BI	Compara indicadores históricos entre grupos.
P2	¿Qué productos presentan patrones de demanda por mes y temporada?	BI	Describe tendencias y estacionalidad en series históricas.
P3	¿Cuáles serían las ventas esperadas por producto y tienda para el siguiente mes?	BA	Busca estimar un resultado futuro mediante un modelo predictivo.

2. Inventario de fuentes

Para este proyecto se propone trabajar con tres fuentes de información. La primera será una base de datos ficticia de ventas, con más de 50.000 registros, que se creará para analizar los ingresos, los descuentos y las ganancias de la empresa. La segunda será la Encuesta Anual de Comercio del DANE, que permitirá conocer mejor la situación del comercio en Colombia. La tercera será la información del Índice de Precios al Consumidor (IPC) del DANE, que servirá para observar los cambios en los precios a lo largo del tiempo.

Estas fuentes se organizarán en archivos CSV y Excel, según corresponda. Antes de finalizar el proyecto, se descargarán y revisarán los archivos públicos para confirmar la cantidad de registros disponibles y verificar que la información sea útil para el análisis.

2.1 Fuentes

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F1. Ventas sintéticas	Generación propia documentada en /datos; sin URL externa	CSV	60.000 filas objetivo (generadas por el equipo)	01/01/2023–31/12/2024	23/10/2026 (fecha de preparación prevista)	Datos sintéticos propios; sin datos personales reales.

Fuente	Procedencia (URL)	Formato	Registros	Periodo	Fecha de descarga	Licencia
F2. Encuesta Anual de Comercio (DANE)	https://microdatos.dane.gov.co/index.php/catalog/865 (EAC 2023)	CSV/ZIP y documentación web	Confirmar en archivo descargado; no usar el total de variables como registros	Año de referencia 2023; complementar con EAC 2022/2024 para horizonte	23/10/2026 (verificar al descargar)	Condiciones de uso y cita indicadas por DANE; revisar la ficha y restricciones de redistribución.
F3. Índice de Precios al Consumidor (DANE)	https://www.dane.gov.co/index.php/estadisticas-por-tema/precios-y-costos/indice-de-precios-al-consumidor-ipc	Excel/CSV según publicación	Confirmar según serie seleccionada	Mínimo 2023–2025	23/10/2026 (verificar al descargar)	Consultar términos de uso y cita del DANE.

2.2 Problemas de calidad detectados

Durante la revisión de la información de Comercial Andina S.A.S. se buscará identificar posibles errores que puedan afectar los resultados del análisis. Algunos problemas que se tendrán en cuenta son las fechas registradas de diferentes maneras, los productos con nombres repetidos o escritos de forma distinta, los valores faltantes y las ventas duplicadas.

También se revisará la información pública del DANE para comprobar que los datos estén completos y que los periodos y las unidades de medida sean adecuados para el proyecto.

Estos problemas se presentan inicialmente como ejemplos de prueba, ya que la empresa es ficticia y todavía se deben revisar los archivos definitivos. Una vez se tengan los datos, se registrarán ejemplos concretos de cada fuente y se definirán las acciones necesarias para corregir las inconsistencias antes de realizar el análisis.

Fuente	Campo	Problema	Ejemplo real del dato
F1	fecha_venta / sku	Casos sintéticos de prueba con formatos y códigos diferentes para validar la limpieza.	Ejemplo de prueba a introducir: 15/02/2023 frente a 02-15-2023; SKU P-01 frente a P01. No corresponde a un archivo descargado.
F2	ventas / periodo / actividad	Validar unidades monetarias, códigos de actividad y comparabilidad entre años; DANE advierte que cambios de cobertura pueden afectar la comparación histórica.	La EAC expresa ventas en miles de pesos en variables como VENTA; revisar ficha y diccionario antes de comparar. Confirmar ejemplo exacto en el archivo.
F3	periodo / variación / índice	Verificar formato de fecha, separadores decimales, cambios de base y consistencia entre variación mensual y anual.	Ejemplo pendiente de extracción literal de la hoja descargada; no inventar un valor. Registrar mes y celda al revisar el archivo.

3. Diagnóstico de madurez

De acuerdo con la situación planteada para Comercial Andina S.A.S., se considera que la empresa se encuentra actualmente en la fase 2 del modelo BIMM, en la que los datos están disponibles, pero todavía no se cuenta con una solución de Business Intelligence que permita analizarlos de manera organizada.

Esto significa que la información de las ventas, los productos y las tiendas puede existir en diferentes archivos, pero su organización dificulta comparar resultados y tomar decisiones con facilidad.

El objetivo del proyecto es avanzar hacia la fase 4, correspondiente al uso de un almacén de datos (Data Warehouse). Esto permitiría reunir la información en un solo lugar, organizarla y facilitar el análisis de las ventas, los descuentos y las ganancias de acuerdo con el tiempo, los productos y las tiendas.

Este avance se plantea como una propuesta, ya que la empresa es ficticia y el nivel de madurez se establece a partir del escenario diseñado para el trabajo. La implementación de la solución se desarrollaría en etapas posteriores.

Elemento	Respuesta
Fase actual	Fase 2 — Datos accesibles sin BI.

Elemento	Respuesta
Evidencia	S1: archivos separados; S2: catálogos sin estandarizar; S3: fechas y unidades sin formato común. No existe una capa integrada de análisis.
Por qué no es la fase siguiente	Para alcanzar la fase 3 se requieren procesos formales y repetibles de decisión basados en datos. En el caso, cada tienda prepara sus archivos de forma independiente y no hay definiciones únicas de indicadores ni responsables de calidad.
Fase objetivo al final del proyecto	Fase 4 — Data warehouse.
Brechas que cierra el proyecto	Integración ETL documentada (capa 2); almacén PostgreSQL con modelo dimensional (capa 3); diccionario y reglas de calidad (capa 5); reportes de indicadores definidos para gerencia (capa 4).

4. Arquitectura

Para Comercial Andina S.A.S. se propone una arquitectura que permita organizar la información de la empresa y facilitar su análisis. La solución estará dividida en varias partes, cada una con una función específica.

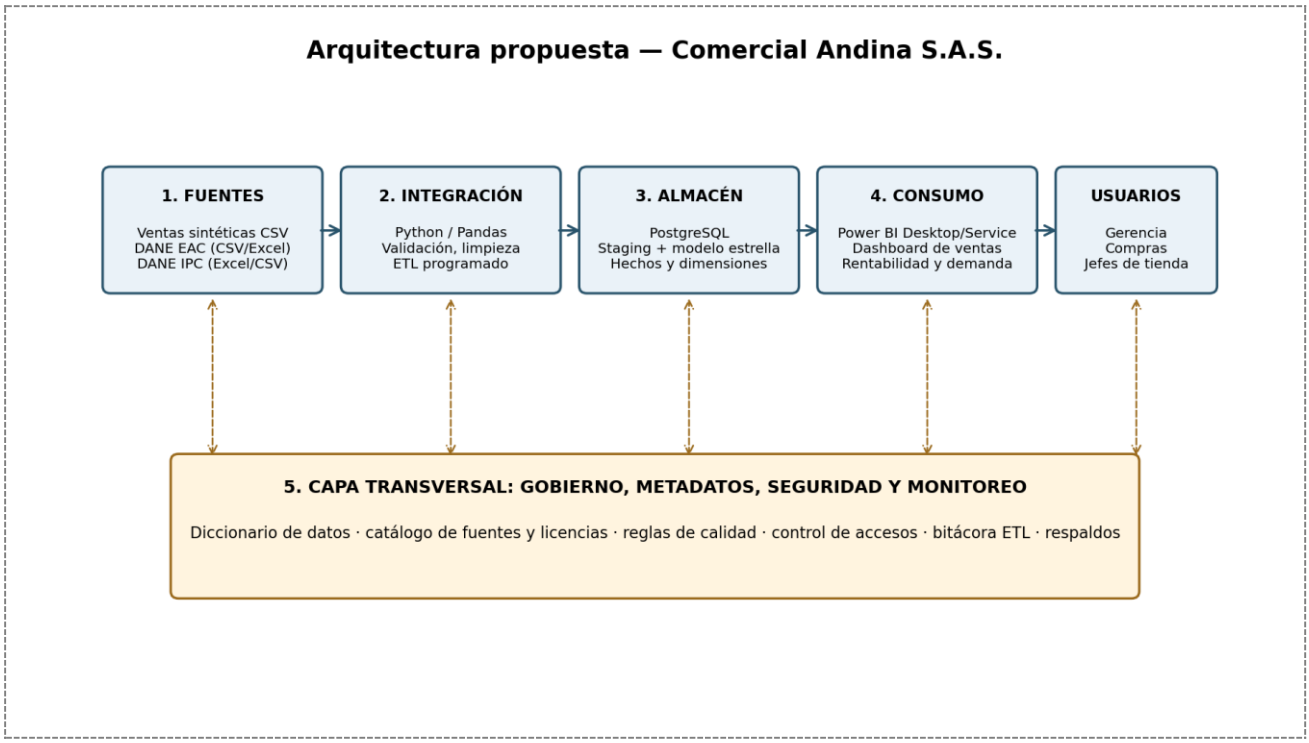
Primero, se tendrán las fuentes de información, que incluyen los datos de ventas de la empresa y los archivos públicos del DANE. Después, se utilizará Python con la herramienta Pandas para organizar los datos, revisar posibles errores y preparar la información para su almacenamiento.

Posteriormente, los datos se guardarán en una base de datos PostgreSQL, que funcionará como un lugar central para mantener la información organizada. Finalmente, se propone utilizar Power BI para presentar los resultados mediante gráficos e informes que permitan comparar las ventas, los descuentos y las ganancias por producto, tienda y periodo.

Durante todo el proceso se tendrán en cuenta aspectos como la calidad de los datos, el origen de la información, los permisos de acceso y el seguimiento de los cambios realizados. Esto ayudará a mantener la información organizada y a generar resultados más confiables.

Esta arquitectura corresponde a una propuesta de diseño para el proyecto. Las herramientas mencionadas todavía no se han implementado y su desarrollo se dejará para las siguientes etapas.

4.1 Diagrama de cinco capas del caso



4.2 Componentes por capa

Capa	Componentes y herramientas del caso	Función en el caso
1. Fuentes de datos	F1 ventas sintéticas CSV; F2 Encuesta Anual de Comercio del DANE; F3 serie IPC del DANE.	Aportar transacciones simuladas y contexto sectorial/económico.
2. Integración (ETL)	Python 3 y Pandas; archivos de configuración; reglas de validación; registros de errores.	Unificar formatos, limpiar nulos y duplicados, normalizar SKU, fechas y unidades.
3. Almacén de datos	PostgreSQL; zona staging; tabla HECHOS_VENTAS y dimensiones.	Guardar datos depurados y habilitar consultas históricas.
4. Usuario final	Power BI Desktop/Service; dashboard para gerente comercial, compras y jefes de tienda.	Visualizar ingresos, utilidad, descuentos, tendencia y demanda por producto/tienda.
5. Gobierno, metadatos, monitoreo y seguridad	Diccionarios, registro de procedencia/licencias, control de accesos, bitácora ETL, reglas de calidad y respaldos.	Asegurar trazabilidad, control de cambios, reproducibilidad y uso responsable de la información.

4.3 Marco de Referencia de cuatro categorías

Categoría	Decisión tomada	Justificación
Arquitectura de información	Indicadores: unidades, ingresos netos, descuentos, costo y utilidad; análisis por mes, producto, tienda y canal.	Responde P0–P3 con definiciones comunes y dimensiones consistentes.
Arquitectura de datos	Modelo dimensional en estrella en PostgreSQL; una tabla de hechos y cuatro dimensiones.	Permite comparar ventas y rentabilidad a través de un mínimo de dos años.
Arquitectura técnica	ETL con Python/Pandas; PostgreSQL administrado en cloud; Power BI para visualización.	Herramientas conocidas, reproducibles y adecuadas para un prototipo académico.
Arquitectura de producto	Dashboard gerencial de ventas, utilidad, descuentos y demanda; exportación de resultados.	Entrega indicadores accionables a gerencia y compras; el dashboard se construirá en una entrega posterior.

4.4 Decisión de despliegue

Se elige una alternativa cloud tipo PaaS para alojar PostgreSQL administrado y compartir reportes mediante un servicio BI. Para un prototipo académico también se puede trabajar localmente; la decisión final depende de presupuesto, cuentas disponibles y condiciones de acceso.

Criterio	On-premise	Opción cloud: PaaS + BI SaaS	Elegida y por qué
Costo	Compra/administración de equipo, copias y mantenimiento; costo inicial mayor.	Pago por uso; algunos niveles gratuitos, pero puede haber cargos por almacenamiento y licencias.	Cloud para el prototipo si hay créditos/cuenta académica; revisar costos antes de publicar.
Seguridad y cumplimiento	Control físico local; responsabilidad de parches y respaldos.	Controles de proveedor, permisos y cifrado; configuración correcta sigue siendo responsabilidad del equipo.	Cloud con acceso restringido; los datos transaccionales son sintéticos y no incluyen datos personales.
Escalabilidad	Depende del hardware disponible.	Puede ampliar almacenamiento y cómputo según necesidad.	Cloud facilita crecer sin comprar servidor propio.
Acceso móvil	Requiere red/VPN y configuración local.	Los reportes publicados pueden consultarse desde navegador o móvil con permisos.	Cloud facilita consulta por gerencia desde distintas sedes.

5. Modelo dimensional

5.1 Proceso de negocio

El proceso de negocio seleccionado para Comercial Andina S.A.S. es la venta de productos en sus tiendas. El análisis tendrá en cuenta cada producto vendido, la fecha de la venta, la tienda donde se realizó y el canal utilizado para atender al cliente.

Con esta información se busca conocer cuánto vende la empresa, cuáles son sus costos y qué ganancias obtiene. También se podrán comparar los resultados entre productos, tiendas y periodos para identificar cuáles tienen un mejor desempeño.

Además, los resultados servirán como apoyo para planear las compras y controlar el inventario, ayudando a identificar qué productos tienen mayor demanda y cuáles necesitan una mejor planificación. En esta primera entrega se define el proceso que se estudiará y la información que se necesitará para analizarlo; la implementación se realizará en una etapa posterior.

5.2 Granularidad

En este proyecto, cada fila de la tabla HECHOS_VENTAS representará un producto vendido dentro de una transacción de Comercial Andina S.A.S. Cada registro estará relacionado con una fecha, una tienda y un canal de venta.

Por ejemplo, si un cliente compra tres productos diferentes en una misma compra, se registrarán tres filas, una por cada producto. Esto permitirá conocer con mayor detalle qué productos se venden, cuánto dinero generan y cuáles son sus costos y ganancias.

Esta forma de organizar la información facilitará la comparación de los resultados por producto, tienda, canal y periodo. La granularidad se define en esta etapa de diseño y se utilizará como guía cuando se construya la base de datos.

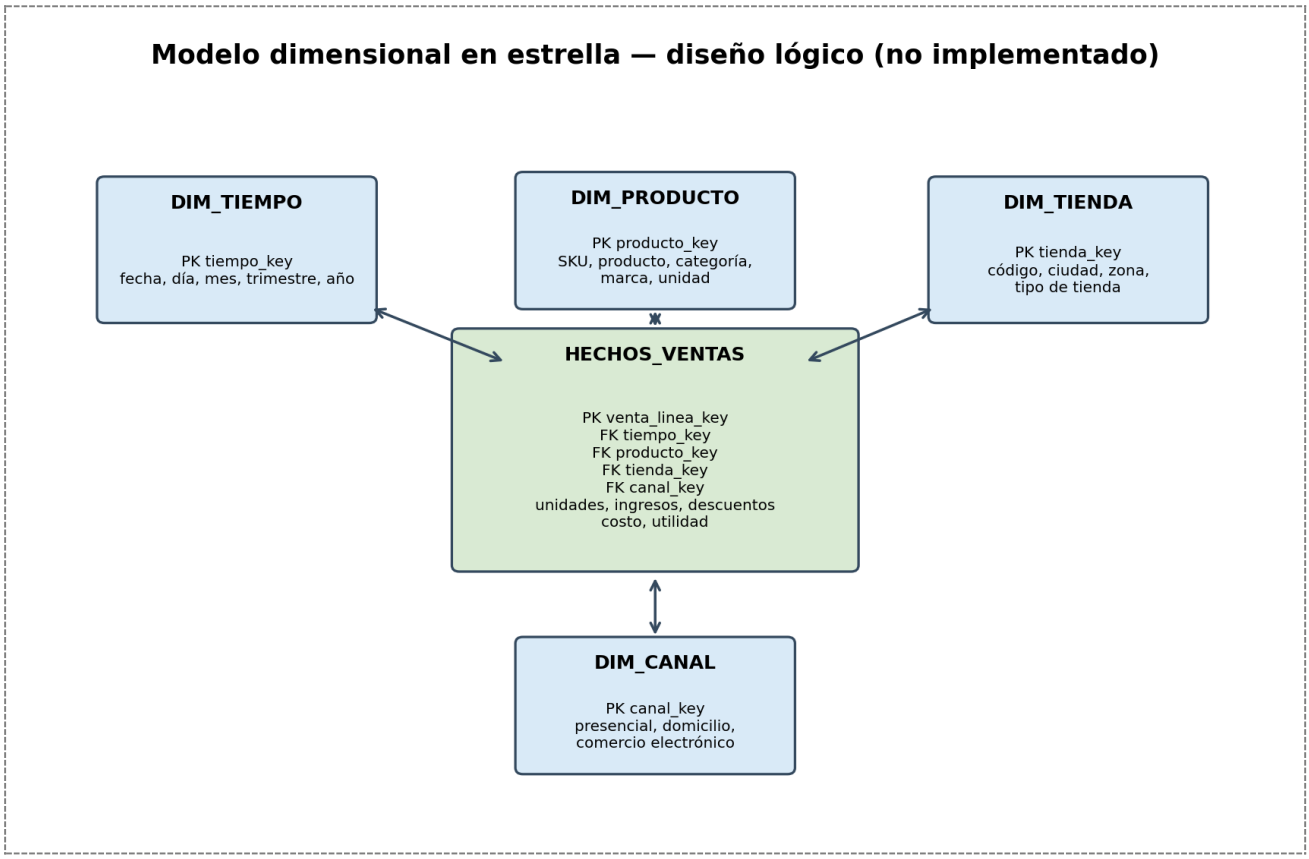
5.3 Métricas de la tabla de hechos

Métrica	Tipo de dato	Aditividad	Origen o fórmula
unidades_vendidas	Entero	Aditiva	Suma de unidades por línea.
ingresos_brutos	Decimal (COP)	Aditiva	unidades × precio_unitario.
descuento_valor	Decimal (COP)	Aditiva	ingresos_brutos × porcentaje_descuento.
costo_total	Decimal (COP)	Aditiva	unidades × costo_unitario.
utilidad	Decimal (COP)	Aditiva	ingresos_brutos − descuento_valor − costo_total.
margen_pct	Decimal (%)	No aditiva	utilidad / (ingresos_brutos − descuento_valor) × 100; recalcular en cada agregado.

5.4 Dimensiones

Dimensión	Atributos principales	Jerarquía	Fuente
Tiempo	fecha, día, mes, nombre_mes, trimestre, año	día → mes → trimestre → año	Generada a partir de fecha_venta
Producto	producto_key, SKU, nombre, categoría, marca, unidad	producto → categoría	Catálogo sintético de productos
Tienda	tienda_key, nombre_tienda, ciudad, zona, tipo_tienda	tienda → ciudad → zona	Catálogo sintético de tiendas
Canal	canal_key, nombre_canal	canal (sin jerarquía inicial)	Ventas sintéticas

5.5 Diagrama del esquema



5.6 Trazabilidad con las preguntas

Pregunta	Métricas que usa	Dimensiones que usa
P0	utilidad, ingresos netos, costo_total	Tiempo, Producto, Tienda
P1	unidades_vendidas, ingresos_brutos, descuento_valor, utilidad	Tiempo, Producto, Tienda, Canal
P2	unidades_vendidas, ingresos netos	Tiempo, Producto, Tienda
P3	unidades_vendidas históricas; variables derivadas de mes/temporada	Tiempo, Producto, Tienda

6. Referencias

Departamento Administrativo Nacional de Estadística (DANE). (2025). Encuesta Anual de Comercio (EAC) 2023. https://microdatos.dane.gov.co/index.php/catalog/865

Departamento Administrativo Nacional de Estadística (DANE). (s. f.). Índice de Precios al Consumidor (IPC). https://www.dane.gov.co/index.php/estadisticas-por-tema/precios-y-costos/indice-de-precios-al-consumidor-ipc

Comercial Andina S.A.S. (2026). Datos transaccionales sintéticos para el proyecto de Business Intelligence [Conjunto de datos generado por el equipo; pendiente de creación].

Anexos

Anexo A. Diccionarios de datos

Campo	Tipo	Descripción	Ejemplo	Problema de calidad
venta_linea_key	Entero / PK	Identificador único de cada línea de venta sintética.	100001	Duplicados de clave deben rechazarse.
fecha_venta	Fecha / FK tiempo	Fecha en que ocurrió la venta.	2023-02-15	Formatos mixtos y fechas inválidas.
sku	Texto / FK producto	Código del producto vendido.	P-01	Variantes de escritura, espacios y ceros iniciales.
tienda_id	Texto / FK tienda	Identificador de tienda.	T03	Códigos faltantes o no existentes en catálogo.
canal	Texto / FK canal	Canal de venta.	Presencial	Variantes de mayúsculas y nombres.
unidades	Entero	Cantidad vendida.	3	Nulos, cero o valores negativos sin devolución asociada.
precio_unitario	Decimal COP	Precio por unidad antes de descuento.	4500.00	Separador decimal y unidades monetarias inconsistentes.
descuento_pct	Decimal (%)	Porcentaje de descuento aplicado.	0.10	Valores fuera del rango 0–1 o mezcla entre 10 y 0.10.
costo_unitario	Decimal COP	Costo unitario simulado.	2800.00	Nulos o costos expresados en miles de pesos.
ingresos_brutos	Decimal COP	Unidades multiplicadas por precio unitario.	13500.00	Inconsistencia si no coincide con unidades × precio.

Anexo B. Diagramas a tamaño completo

.